

Um workflow em Python para a análise de dados de questionários: aplicação ao estudo da literacia da leitura

A Python-based workflow for the analysis of survey data: application to the study of reading literacy

Alexandre Reis¹, Daniela Castro², Mara Lobo³, Patrick Alves⁴

Resumo

Este estudo apresenta um workflow metodológico para a análise de dados estruturados e semiestruturados com Python, desenvolvido no âmbito das Humanidades Digitais e validado através de um questionário aplicado à literacia da leitura. Partindo de uma conceção alargada de corpus, que integra dados provenientes de surveys tratados como objetos analíticos estruturados, o trabalho articula análise exploratória, construção de índices compostos e visualização gráfica, com integração pontual de Inteligência Artificial generativa (IAGen) como recurso auxiliar ao processo interpretativo. O workflow recorre a bibliotecas Python, nomeadamente Pandas, e adota uma abordagem iterativa, transparente e reproduzível, na qual a automatização computacional é mediada por curadoria humana contínua. Os resultados evidenciam a eficácia do workflow na identificação e validação de padrões, sublinhando o potencial de workflows computacionais para apoiar a produção de conhecimento nas Humanidades Digitais com rigor metodológico e interpretação crítica, independentemente do domínio substantivo em análise.

Palavras-chave: *Análise de corpora; Análise exploratória de dados; Humanidades Digitais; Literacia da leitura; Python; Workflows computacionais.*

Abstract

This study presents a methodological workflow for the analysis of structured and semi-structured data using Python, developed within the field of Digital Humanities and validated through a reading literacy questionnaire. Adopting an expanded conception of corpus that includes survey data treated as structured analytical objects, the study combines exploratory data analysis, the construction of composite indices, and graphical visualisation, with selective support from generative Artificial Intelligence (GenAI) as an auxiliary interpretive resource. The workflow integrates Python libraries, notably Pandas, and follows an iterative, transparent, and reproducible approach, in which computational automation is continuously mediated by human curation. The results demonstrate the effectiveness of the proposed workflow in identifying and validating patterns, highlighting the potential of computational workflows to support knowledge production in Digital Humanities with methodological rigour and critical interpretation, beyond the specific empirical domain examined.

Keywords: *Computational workflows; Corpus analysis; Digital Humanities; Exploratory data analysis; Python; Reading literacy.*

¹ Universidade do Minho, Estudante do Mestrado em Humanidades Digitais 2025/2026, salgadodosreis21@gmail.com

² Universidade do Minho, Estudante do Mestrado em Humanidades Digitais 2025/2026, dancastrolib@gmail.com

³ Universidade do Minho, Estudante do Mestrado em Humanidades Digitais 2025/2026, maralobo@gmail.com

⁴ Universidade do Minho, Estudante do Mestrado em Humanidades Digitais 2025/2026, patrickalves694@gmail.com

1. Introdução

As Humanidades Digitais (HD) representam um campo de intersecção no qual a computação não serve apenas como ferramenta, mas como uma lente epistemológica que influencia a formulação de problemas, a organização dos dados e a produção de conhecimento. A análise de conjuntos extensos e heterogêneos de dados — incluindo textos, metadados e dados semiestruturados — coloca desafios às abordagens exclusivamente baseadas na leitura interpretativa tradicional (*close reading*), abrindo espaço a metodologias que privilegiam a identificação sistemática de padrões e regularidades em larga escala. Neste sentido, a proposta de *distant reading* de Franco Moretti tem sido amplamente reconhecida como uma estratégia metodológica complementar, orientada para a exploração computacional de corpora extensos (Moretti, 2013).

Apesar da consolidação de métodos computacionais nas Humanidades Digitais, a literatura revela uma escassez de descrições explícitas e reproduzíveis de workflows analíticos aplicados a dados semiestruturados, como os provenientes de questionários. Em muitos estudos empíricos, os instrumentos de recolha e os resultados são apresentados de forma detalhada, mas os processos computacionais que medeiam a organização, a transformação e a análise dos dados permanecem frequentemente implícitos, limitando a transparência e a transferibilidade metodológica. Embora tradicionalmente associados às ciências sociais empíricas, os dados provenientes de questionários podem ser integrados em práticas das Humanidades Digitais quando analisados através de workflows computacionais explícitos, interpretativos e reproduzíveis.

É neste contexto que o presente artigo propõe um workflow metodológico com Python para a análise de dados estruturados e semiestruturados, desenvolvido no âmbito das Humanidades Digitais. Partindo de uma conceção alargada de corpus, os dados provenientes de um questionário sobre literacia da leitura são tratados como objetos analíticos estruturados, suscetíveis de exploração computacional sistemática. O workflow articula procedimentos de organização tabular dos dados, construção de índices compostos, análise exploratória e visualização gráfica, integrando apoio pontual de IAGen como recurso auxiliar ao processo interpretativo, sob curadoria humana contínua.

O contributo central do artigo não reside na discussão substantiva dos resultados empíricos do questionário, mas na explicitação de um modelo de workflow analítico transparente, reproduzível e transferível, aplicável a diferentes contextos de investigação que recorram a dados semiestruturados. A relevância deste trabalho decorre, assim, da necessidade crescente dos investigadores em Humanidades desenvolverem literacia computacional que lhes permita lidar de forma crítica e informada com dados digitais.

2. Enquadramento teórico e metodológico

No âmbito das Humanidades Digitais, a computação é progressivamente entendida como parte integrante do processo de investigação, influenciando não apenas os meios técnicos utilizados, mas também as formas de conceptualização, operacionalização e interpretação dos dados. Esta perspetiva implica reconhecer que os procedimentos computacionais — desde a estruturação dos dados até às operações analíticas e de visualização — constituem escolhas metodológicas com implicações epistemológicas, devendo ser tornadas explícitas e discutidas no texto científico (Kirschenbaum, 2010; Burdick et al., 2012). A adoção de workflows computacionais não se limita, assim, à automatização de tarefas, mas integra-se num quadro reflexivo em que método, infraestrutura e interpretação se articulam.

A análise de *corpora* constitui hoje um eixo central das Humanidades Digitais, permitindo explorar grandes volumes de dados textuais através de métodos computacionais que complementam a leitura interpretativa tradicional. A literatura sublinha que os *corpora* anotados funcionam como uma ponte entre a superfície linguística e o conteúdo conceptual, possibilitando ciclos iterativos entre análise quantitativa e leitura qualitativa,

em vez de *pipelines* estritamente lineares (Kuhn, 2019). Neste enquadramento, a noção de *workflow computacional end-to-end* não remete para uma linearidade rígida, mas para a explicitação reflexiva de todas as etapas do processo analítico, desde a ingestão dos dados até à interpretação, como condição de transparência e reprodutibilidade (Sandve et al., 2013). Contudo, em muitos estudos empíricos que recorrem a dados de questionários ou outros materiais semiestruturados, a explicitação detalhada destes pipelines permanece limitada, sendo frequente a descrição dos instrumentos e dos resultados sem uma documentação sistemática dos procedimentos computacionais intermédios.

Grande parte da investigação baseada em questionários tende a privilegiar os modelos conceituais subjacentes e a apresentação dos resultados empíricos, deixando frequentemente implícitos os processos computacionais que medeiam a organização, transformação e análise dos dados. Este padrão é observável também em estudos no domínio da literacia e da literacia digital, nos quais os instrumentos de recolha são cuidadosamente descritos, mas os procedimentos analíticos permanecem, em muitos casos, subespecificados ou pouco documentados (Makhachashvili & Semenist, 2022). A ausência de explicitação dos workflows limita não apenas a reprodutibilidade, mas também a transferibilidade das abordagens metodológicas para outros contextos de investigação e para outros tipos de dados semiestruturados.

É neste enquadramento que o presente trabalho propõe tratar dados provenientes de questionários como objetos analíticos estruturados, aproximando práticas de análise de corpora textuais do trabalho com dados semiestruturados. Esta perspetiva permite enquadrar os questionários num pipeline computacional coerente, no qual operações como normalização, derivação de variáveis, construção de índices compostos e análise exploratória são integradas de forma sistemática e transparente. A construção de índices compostos surge, neste enquadramento, como um mecanismo central de operacionalização, permitindo a agregação de múltiplos itens em dimensões analíticas interpretáveis, ao mesmo tempo que estabiliza a leitura dos dados e facilita a comparação entre participantes e dimensões.

A análise exploratória e a visualização gráfica desempenham igualmente um papel metodológico relevante, não apenas como instrumentos de comunicação de resultados, mas como dispositivos de validação interpretativa. Distribuições, gráficos comparativos e matrizes de correlação permitem identificar padrões, assimetrias e incoerências que informam decisões metodológicas subsequentes e apoiam a leitura crítica dos dados, em consonância com práticas consolidadas de análise exploratória em contextos computacionais.

A utilização de Inteligência Artificial neste contexto é enquadrada numa perspetiva de sistemas co-inteligentes, em que a automatização computacional apoia — mas não substitui — o raciocínio analítico do investigador, reforçando a articulação entre capacidades humanas e computacionais na produção de conhecimento (Burdick et al., 2012; Mollick & Mollick, 2024). Nesta linha, Mollick e Mollick (2024) defendem abordagens *human-in-the-loop*, nas quais o investigador humano permanece como agente central das decisões metodológicas, cabendo à IA um papel de apoio cognitivo, de explicitação do raciocínio e de validação interpretativa. No workflow aqui proposto, a IAGen é utilizada de forma deliberadamente limitada, reflexiva e contextualizada, nomeadamente no apoio à clarificação e documentação do processo analítico e na verificação de coerência descritiva entre etapas, mantendo-se a interpretação dos resultados sob responsabilidade do investigador.

Em síntese, o enquadramento teórico e metodológico adotado neste estudo combina contributos das Humanidades Digitais, da investigação computacional reprodutível e da análise exploratória de dados, sustentando a proposta de um workflow metodológico explícito, transferível e criticamente informado. Este enquadramento fornece a base conceptual para a descrição do workflow e para a sua validação empírica, apresentadas nas secções seguintes.

3. Corpus, dados e material empírico

O corpus utilizado neste trabalho resulta de um questionário exploratório sobre literacia da leitura, concebido para recolher dados relativos a práticas, competências, atitudes e preferências de leitura em contextos digitais e não digitais. O instrumento foi aplicado a uma amostra de 32 participantes, originando um conjunto de dados composto por 93 variáveis, que integra maioritariamente itens de resposta em escala de Likert, bem como perguntas categóricas e um conjunto limitado de variáveis sociodemográficas, configurando um corpus de dados estruturados e semiestruturados.

Em coerência com uma conceção alargada de corpus adotada no âmbito das Humanidades Digitais, os dados provenientes do questionário são tratados como objetos analíticos passíveis de exploração computacional sistemática. Esta conceção não decorre da natureza do instrumento em si, mas da sua integração num workflow que torna explícitas as operações analíticas aplicadas ao corpus. Esta abordagem desloca o foco do questionário enquanto mero instrumento de recolha para o considerar como um corpus estruturado, cujos itens, respostas e metadados podem ser organizados, transformados e analisados de forma integrada ao longo de um processo analítico reproduzível.

Os dados foram recolhidos através de uma plataforma digital, exportados em formato tabular (CSV) e analisados em ambientes de análise computacional baseados em *notebooks*, tais como Jupyter Notebook ou Google Colab, utilizando Python como linguagem integradora. Antes da análise, procedeu-se à identificação das variáveis em escala de Likert e à verificação da consistência do intervalo de resposta (1–6), assegurando condições mínimas de qualidade analítica para as etapas de normalização e agregação subsequentes. Neste processo de preparação dos dados, foram ainda realizadas operações de normalização de rótulos, verificação da consistência das escalas de resposta e tratamento de valores ausentes.

O questionário não é mobilizado como objeto de análise substantiva autónoma, mas como caso de validação empírica do workflow metodológico proposto. A sua estrutura, composta por múltiplos itens distribuídos por diferentes dimensões analíticas — hábitos funcionais, tarefas funcionais, estratégias de leitura, segurança e credibilidade da informação, motivação e atitudes, preferências de formato e práticas de leitura multimédia —, oferece um contexto adequado para testar procedimentos de organização de dados, construção de índices compostos, análise exploratória e visualização gráfica, sem restringir a aplicabilidade do workflow a um domínio temático específico.

A Figura 1 apresenta um excerto da tabela de dados após a importação para o ambiente de análise, ilustrando a estrutura tabular do corpus e a organização das variáveis antes das etapas de limpeza, normalização e agregação.

Timestamp	Qual a sua faixa etária?	Região onde vive habitualmente	Localização da sua área de residência	Sexo registado à nascença	Qual é o nível mais alto de escolaridade concluído?	Situação profissional atual	Nasceu em Portugal?	País ou região de nascimento	Há quantos anos vive em Portugal? \n	Compreendo melhor textos em papel do que no ecrã.\n	A leitura digital permite-me aceder mais facilmente à informação.	As distrações digitais reduzem a minha concentração na leitura.	A leitura em ecrã é tão eficaz como a leitura em papel.	O formato não afeta a minha compreensão.	Considero-me uma pessoa que gosta de ler.	Sinto-me motivado/a para ler regularmente.	Ler ajuda-me a compreender melhor o mundo.	Gostava de ter mais tempo para ler.	Recomendo livros e leituras a outras pessoas.
0	10/23/2025 9:42:04	10-24	Norte	Semi-urbana	Feminino	Ensino secundário (12.º ano)	Estudante a tempo parcial	Não	Ásia	<1 ...	1	5	2	5	5	5	5	5	5
1	10/23/2025 9:42:37	10-24	Norte	Urbana	Masculino	Ensino secundário (12.º ano)	Trabalhador/a por conta própria / Empresário/a	Não	Brasil	<1 ...	5	5	5	4	4	5	5	5	5
2	10/23/2025 9:42:52	10-24	Norte	Urbana	Feminino	Ensino secundário (12.º ano)	Estudante a tempo inteiro	Não	Brasil	3-5 ...	5	4	5	1	2	5	5	5	5
3	10/23/2025 9:44:28	10-24	Norte	Urbana	Feminino	Ensino secundário (12.º ano)	Estudante a tempo inteiro	Sim	Europa (fora UE)	11-20 ...	5	3	4	3	2	3	2	4	4
4	10/23/2025 9:47:30	10-24	Norte	Rural	Masculino	Ensino secundário (12.º ano)	Estudante a tempo inteiro	Não	Outro país da UE	3-5 ...	3	4	5	4	4	4	2	3	5

5 rows x 93 columns

Figura 1 - Excerto da tabela de dados após importação e inspeção inicial em ambiente Colab.

4. Infraestrutura técnica e bibliotecas Python

A implementação do workflow metodológico recorreu a um ecossistema de bibliotecas Python orientadas para a análise de dados estruturados e semiestruturados, privilegiando a transparência dos procedimentos, a reprodutibilidade e a articulação entre análise exploratória e validação interpretativa. A arquitetura técnica assenta na biblioteca Pandas como estrutura central do *workflow*, permitindo organizar os dados provenientes do questionário — um corpus semiestruturado composto por itens em escala de Likert, variáveis categóricas e metadados — em *DataFrames* flexíveis e explicitamente documentados.

O uso de Pandas revelou-se determinante para a operacionalização do workflow, possibilitando a inspeção inicial do *dataset*, a normalização de variáveis, o tratamento de valores ausentes e a construção de índices compostos a partir da agregação de múltiplos itens conceptualmente relacionados. Ao tornar explícitas, no código, as transformações aplicadas aos dados, esta abordagem reforça a rastreabilidade das operações analíticas e favorece a reprodutibilidade do processo, na medida em que incorpora as decisões metodológicas como parte integrante do próprio workflow (Sandve et al., 2013; Kuhn, 2019).

Para o cálculo de estatísticas descritivas, médias e correlações entre índices, o workflow integrou a biblioteca NumPy, assegurando operações vetoriais consistentes e eficientes que sustentam a análise quantitativa subjacente à exploração dos dados. A análise exploratória foi complementada por bibliotecas de visualização, nomeadamente Matplotlib e Seaborn, utilizadas na produção de gráficos exploratórios — *scatterplots*, *boxplots*, histogramas e *heatmaps* de correlação. Estas visualizações não foram mobilizadas apenas como instrumentos de comunicação de resultados, mas como dispositivos analíticos que permitem identificar padrões, assimetrias e incoerências internas, desempenhando um papel ativo no processo interpretativo (Rule et al., 2019).

Para além do seu papel instrumental, a utilização de Python assume neste trabalho uma função metodológica central. A linguagem funciona como elemento integrador do workflow analítico, articulando, num único ambiente computacional, a preparação dos dados, a construção de índices compostos, a análise exploratória e a produção de visualizações. Esta integração contribui para a estabilização das decisões metodológicas, uma vez que cada operação aplicada aos dados é explicitamente codificada, documentada e passível de auditoria, reforçando a transparência e a replicabilidade do processo analítico (Sandve et al., 2013).

A execução do workflow decorreu em ambientes baseados em notebooks computacionais, nomeadamente **Google Colab**, que permitem combinar código executável, resultados intermédios, visualizações gráficas e comentários interpretativos num mesmo artefacto reprodutível. Esta configuração favorece práticas de investigação iterativas e reflexivas, nas quais o investigador pode regressar a etapas anteriores do workflow à luz de novos resultados, mantendo uma curadoria humana contínua sobre as operações computacionais realizadas. Tal abordagem está em consonância com recomendações da literatura sobre investigação computacional reprodutível e documentação explícita de análises em ambientes de notebook (Rule et al., 2019).

Neste contexto, Python é entendido não apenas como uma ferramenta de apoio técnico, mas como um meio de explicitação das decisões analíticas que estruturam o processo de investigação. Esta perspetiva aproxima-se das abordagens defendidas no campo das Humanidades Digitais, que sublinham a importância de tornar visíveis os procedimentos computacionais que mediam a produção de conhecimento, reforçando o rigor metodológico e a interpretação crítica dos dados (Kirschenbaum, 2010; Burdick et al., 2012).

5. Workflow metodológico proposto

O workflow metodológico desenvolvido neste estudo foi concebido para apoiar a análise sistemática de dados estruturados e semiestruturados em contextos de investigação nas Humanidades Digitais, com especial ênfase

na transparência dos procedimentos, na reprodutibilidade e na curadoria humana contínua. Em consonância com o enquadramento teórico apresentado, o *workflow* não é entendido como um *pipeline* linear rígido, mas como uma estrutura modular e iterativa, na qual diferentes etapas podem ser revistas e ajustadas à luz de resultados intermédios e de decisões interpretativas. Esta abordagem permite articular operações computacionais e reflexão metodológica num processo integrado, no qual a análise quantitativa e a interpretação crítica se informam mutuamente. A estrutura global do workflow e a articulação entre as suas etapas são sintetizadas na Figura 2.



Figura 2 - Representação conceptual do workflow metodológico proposto.

O workflow organiza-se em cinco etapas principais — definição do objetivo e do corpus, importação e inspeção dos dados, limpeza e normalização, construção de índices compostos e análise exploratória com produção de outputs — concebidas como módulos iterativos e interdependentes. A IAGen não constitui uma etapa autónoma do workflow, sendo integrada de forma transversal como camada de apoio à validação crítica, à organização do processo e à curadoria humana contínua, em consonância com uma abordagem *human-in-the-loop*.

Em termos operacionais, o workflow é concebido como uma estrutura modular e iterativa, na qual as diferentes etapas podem ser revistas e ajustadas à luz de resultados intermédios e de decisões interpretativas. Esta lógica evita uma leitura linear do processo analítico e reforça a articulação entre operações computacionais e curadoria humana contínua.

A **primeira etapa** consiste na **definição do objetivo analítico e do corpus**, incluindo a formulação das perguntas de investigação, a identificação das dimensões a operacionalizar e a delimitação dos outputs esperados. Esta fase orienta toda a estrutura subsequente do workflow, assegurando a coerência entre os objetivos de investigação, as variáveis selecionadas e os procedimentos computacionais adotados. Em coerência com uma conceção alargada de corpus no âmbito das Humanidades Digitais, os dados provenientes de questionários são tratados como objetos analíticos estruturados, passíveis de exploração computacional sistemática, e não apenas como instrumentos de recolha empírica.

A **segunda etapa** corresponde à **importação e inspeção inicial dos dados**, realizada em ambiente computacional com recurso à biblioteca Pandas. Nesta fase procede-se à verificação da dimensão do conjunto de dados, dos tipos de variáveis, da distribuição das respostas e da eventual existência de valores em falta. Esta inspeção inicial permite assegurar a integridade do corpus e constitui uma condição prévia para as transformações analíticas subsequentes, tornando explícitas as características do material empírico antes de qualquer agregação ou análise interpretativa.

A **terceira etapa** envolve a **limpeza e normalização dos dados**, compreendendo operações como a harmonização de rótulos, a verificação da consistência das escalas de resposta e a identificação de itens formulados em sentido negativo. Embora frequentemente tratadas como tarefas preliminares, estas operações são aqui entendidas como decisões metodológicas com impacto direto nos resultados analíticos, devendo, por isso, ser explicitamente documentadas e integradas no workflow. A formalização destas operações em código contribui para a rastreabilidade das transformações aplicadas aos dados e permite a revisão crítica das escolhas efetuadas ao longo do processo. Em particular, os itens formulados em sentido negativo foram previamente identificados e invertidos, garantindo que valores mais elevados correspondem consistentemente a níveis mais elevados da dimensão analisada. Após a inversão, procedeu-se à renomeação dos itens para formulações positivas semanticamente equivalentes, de modo a facilitar a leitura e interpretação dos resultados.

A **quarta etapa**, central no workflow proposto, consiste na **construção de índices compostos** a partir da agregação de múltiplos itens conceptualmente relacionados. Esta etapa permite operacionalizar dimensões analíticas interpretáveis — como hábitos funcionais, estratégias de leitura ou segurança e credibilidade da informação — reduzindo a complexidade dos dados sem perda de densidade conceptual. A seleção dos itens, a definição dos agrupamentos conceptuais e o método de agregação adotado são decisões explicitadas no próprio código, garantindo coerência entre o instrumento de recolha e a operacionalização analítica das dimensões estudadas. De forma complementar, e atendendo ao carácter exploratório do estudo, foi realizada uma avaliação exploratória da consistência interna dos índices através do coeficiente alfa de Cronbach, utilizada como indicador diagnóstico e não como critério de exclusão ou reformulação. Em termos operacionais, cada índice composto foi calculado como a média aritmética simples dos itens que o integram, após a conversão das respostas para formato numérico e a inversão dos itens formulados em sentido negativo, garantindo que valores mais elevados correspondem sistematicamente a níveis mais elevados da dimensão analisada. No conjunto de dados utilizado não se verificaram valores em falta nas respostas aos itens em escala de Likert, pelo que todas as observações foram incluídas no cálculo dos índices e nas análises subsequentes. Não foram aplicados procedimentos automáticos de remoção de outliers, privilegiando-se uma inspeção exploratória das distribuições enquanto parte integrante da variabilidade observada no corpus.

Importa sublinhar que cada uma das etapas do workflow descrito corresponde a blocos de código explicitamente definidos e reutilizáveis, nos quais as opções metodológicas — como a normalização dos itens, a inversão de formulações negativas, a definição dos agrupamentos conceptuais e o cálculo dos índices compostos — são formalizadas de forma transparente. Ao inscrever estas decisões no próprio código, o

workflow transforma-se num objeto metodológico em si mesmo, tornando visíveis escolhas que, em abordagens tradicionais, permanecem frequentemente implícitas ou subespecificadas. Esta explicitação contribui para reforçar a auditabilidade do processo analítico e para clarificar o encadeamento lógico entre dados, operações computacionais e resultados interpretativos.

A **quinta etapa** integra a **análise exploratória, a visualização gráfica e a produção dos outputs analíticos**. Nesta fase são calculadas correlações entre índices compostos, produzidas visualizações como *scatterplots*, histogramas, *boxplots* e *heatmaps*, e organizados os resultados de forma a apoiar a interpretação crítica dos dados. As visualizações não são mobilizadas apenas como instrumentos de comunicação, mas como dispositivos analíticos que permitem identificar padrões, assimetrias e incoerências internas, podendo motivar regressos a etapas anteriores do workflow. Esta lógica iterativa é consistente com práticas consolidadas de análise exploratória em contextos computacionais (Sandve et al., 2013; Rule et al., 2019).

Neste sentido, o recurso a Python não se limita à automatização de tarefas analíticas, mas funciona como uma **forma de escrita metodológica** que documenta o raciocínio do investigador e permite a replicação, adaptação ou extensão do workflow a outros conjuntos de dados semiestruturados. Esta característica confere ao workflow um carácter transferível, compatível com diferentes contextos de investigação nas Humanidades Digitais que recorram a dados provenientes de questionários ou instrumentos semelhantes. Ao articular transparência computacional e curadoria humana contínua, o workflow proposto contribui para reforçar o rigor metodológico e a interpretabilidade dos resultados, sem abdicar da dimensão crítica que caracteriza a investigação nas Humanidades Digitais.

6. Validação empírica: resultados e discussão

A aplicação do workflow metodológico ao conjunto de dados do questionário — organizado em formato tabular (CSV) e operacionalizado através de índices compostos — permitiu identificar associações positivas de magnitude moderada entre várias dimensões da literacia da leitura. Destacam-se, em particular, as relações entre motivação para a leitura e práticas de leitura multimédia, entre estratégias de leitura e hábitos funcionais, e entre competências funcionais de leitura e literacia digital crítica. Estas associações manifestaram-se de forma consistente tanto nas análises estatísticas, expressas pelos coeficientes de correlação de Pearson, como nas visualizações exploratórias produzidas, nomeadamente na matriz de correlação entre índices compostos (Figura 3) e no *scatterplot* entre competências funcionais e segurança/credibilidade da informação (Figura 4), reforçando a coerência dos outputs produzidos pelo processo analítico implementado. Contudo, estas associações devem ser lidas com cautela, dado o número reduzido de participantes ($n = 32$) e o carácter exploratório do estudo. A dimensão amostral limita a potência estatística das análises, desaconselhando a extrapolação dos resultados para além do contexto específico em que o questionário foi aplicado e reforçando a sua leitura sobretudo como prova de conceito do workflow proposto.




Figura 3 - Matriz de correlação (Pearson) entre índices compostos de literacia da leitura.




Figura 4 - Scatterplot entre índices de hábitos/tarefas funcionais e segurança/credibilidade da informação.

Em contraste, as análises revelaram associações fracas ou inexistentes entre o índice de preferências de formato de leitura e as restantes dimensões analisadas, como evidenciado pelos coeficientes de correlação e pelas visualizações comparativas correspondentes. Este resultado sugere que a afinidade com formatos digitais ou em papel, considerada isoladamente, não constitui um fator explicativo determinante das variações observadas nas restantes competências e práticas de literacia da leitura. A coexistência de relações moderadas e de correlações nulas ou muito reduzidas evidencia a utilidade do workflow não apenas para identificar padrões relevantes, mas também para confirmar empiricamente a ausência de associações significativas.

Do ponto de vista metodológico, estes resultados funcionam como validação empírica do workflow proposto. A articulação entre organização tabular dos dados, construção de índices compostos, análise exploratória e visualização gráfica demonstrou ser eficaz para transformar dados brutos provenientes de surveys em informação analiticamente interpretável. Importa sublinhar que o contributo central desta secção não reside na generalização substantiva dos resultados, mas na demonstração de que o workflow computacional, sob curadoria humana, permite explorar dados de questionário de forma metodologicamente informada, transparente e reproduzível. O caso empírico analisado resulta de um projeto de investigação de âmbito académico, apresentando um alcance limitado e sendo mobilizado neste artigo essencialmente como contexto de validação metodológica do workflow proposto.

7. Reflexão crítica final e conclusões

A integração de bibliotecas Python e modelos de Inteligência Artificial neste workflow demonstra que a descoberta de padrões em *corpora* não reside na automatização total, mas numa simbiose entre a escala computacional e a sensibilidade hermenêutica. Ao longo deste processo, a prática nas Humanidades Digitais revelou que a literacia computacional é, fundamentalmente, uma nova forma de escrita crítica. A transição da leitura tradicional para a manipulação técnica de um *corpus* exigiu um rigor e uma precisão ímpares, uma vez que a estruturação de dados em Python não permite as ambiguidades frequentemente toleradas na análise puramente qualitativa. Esta experiência forçou uma objetividade metodológica que acaba por robustecer a validade da interpretação final.

O workflow apresentado não se propõe como um modelo universal, mas como uma estrutura metodológica adaptável, passível de ser reconfigurada em função de diferentes objetos de estudo, escalas de dados e perguntas de investigação.

Neste percurso, a interação entre o investigador e a Inteligência Artificial processou-se como uma negociação constante de papéis, onde a máquina serviu de assistente para a eficiência técnica enquanto o humano assumiu o papel de curador ético e interpretativo. Os limites da IA, como a sua tendência para a generalização ou o risco de alucinação, foram mitigados por ciclos de validação humana, garantindo que a tecnologia servisse a hermenêutica e não o contrário. Esta dinâmica de trabalho colaborativo estabelece um precedente valioso que pode ser facilmente transposto para outros contextos, desde o ensino secundário e universitário até à gestão cultural e investigação documental. A capacidade de articular ferramentas de análise de dados com o pensamento crítico prepara o investigador para enfrentar a explosão da cultura digital, permitindo que projetos futuros beneficiem de uma infraestrutura que é, ao mesmo tempo, reproduzível, transparente e profundamente humana. Em suma, o humanista digital afirma-se não apenas como um utilizador de ferramentas, mas como um arquiteto de novos métodos que garantem a produção de conhecimento rigoroso na era da abundância de dados.

Referências bibliográficas

- Burdick, A., Drucker, J., Lunenfeld, P., Presner, T., & Schnapp, J. (2012). *Digital humanities*. Cambridge, MA: MIT Press.
- Kirschenbaum, M. G. (2010). What is digital humanities and what's it doing in English departments? *ADE Bulletin*, 150, 55–61. <https://doi.org/10.1632/ade.150.55>
- Kuhn, J. (2019). Computational hermeneutics. In M. Schreibman, S. Siemens, & J. Unsworth (Eds.), *A new companion to digital humanities* (pp. 363–376). Wiley Blackwell. <https://doi.org/10.1002/9781118680605.ch25>
- Moretti, F. (2013). *Distant reading*. London: Verso.
- Makhachashvili, R., & Semenist, I. (2022). Dynamic assessment of e-learning in foreign languages programs in sustainable and emergency digitization formats. *ICERI2022 Proceedings*. <https://doi.org/10.21125/iceri.2022.1103>
- Mollick, E., & Mollick, L. (2024). *Co-intelligence: Living and working with AI*. New York: Portfolio.
- Rule, A., Birmingham, A., Zuniga, C., Altintas, I., Huang, S. C., Knight, R., ... Hellerstein, J. M. (2019). Ten simple rules for writing and sharing computational analyses in Jupyter notebooks. *PLoS Computational Biology*, 15(7), e1007007. <https://doi.org/10.1371/journal.pcbi.1007007>
- Sandve, G. K., Nekrutenko, A., Taylor, J., & Hovig, E. (2013). Ten simple rules for reproducible computational research. *PLoS Computational Biology*, 9(10), e1003285. <https://doi.org/10.1371/journal.pcbi.1003285>.